

TD8 : Tests du χ^2 d'indépendance et tests d'ajustement à une loi.

Exercice 1. p. 119.

1. On effectue un test d'indépendance entre 1) les caractères "Conventionnel" et "Bio", et 2) les traces de résidus.

On a :

• X = variable aléatoire à $I = 2$ modalités : {"conventionnel", "bio"}.

• Y = variable aléatoire à $J = 3$ modalités : {"pas de résidus", " $< LNR$ ", " $> LNR$ "}

Hypothèses du test :

$\left\{ \begin{array}{l} H_0 : "X \text{ et } Y \text{ sont indépendantes}" \\ H_1 : "X \text{ et } Y \text{ ne sont pas indépendantes.}" \end{array} \right.$

Statistique de test :

Soient : n_{ij} ($i \in \{1 \dots I\}$, $j \in \{1 \dots J\}$).

Le nombre d'observations de $\{X = i^{\text{e}} \text{ modalité}\}$ et

$\{Y = j^{\text{e}} \text{ modalité}\}$.

$\cdot d_{ij}$ ($i \in \{1 \dots I\}$, $j \in \{1 \dots J\}$)

l'effectif théorique de $\{X = i^{\text{e}} \text{ modalité}\}$ et $\{Y = j^{\text{e}}$

modalité j dans le cas d'indépendance de X et Y .

Alors la statistique du test :

$$D^2 = \sum_{i=1}^I \sum_{j=1}^J \frac{(n_{ij} - d_{ij})^2}{d_{ij}}$$

Suit sous H_0 une loi du χ^2 à $\underbrace{(I-1)}_{1} \underbrace{(J-1)}_{2}$ degrés de liberté, i.e. :

$$D^2 \underset{H_0}{\sim} \chi^2_2.$$

Zone de rejet:

au risque $\alpha = 0.05$, on note q le quantile d'ordre $1 - \alpha$ de la loi du χ^2 à $(I-1)(J-1)$ ddl.

La région de rejet est définie par :

$$R = \{ D^2 > q \}.$$

2. Application.

On commence par calculer les effectifs théoriques dans le cas d'indépendance. On a :

Observations:

	$j = 1$	$j = 2$	$j = 3$	marge.
$i = 1$	$n_{11} = 195$	$n_{12} = 99$	$n_{13} = 6$	$n_{10} = 300$
$i = 2$	$n_{21} = 212$	$n_{22} = 33$	$n_{23} = 5$	$n_{20} = 250$
marge	$n_{.1} = 407$	$n_{.2} = 132$	$n_{.3} = 11$	$n = 550$

Théorie.

	$j = 1$	$j = 2$	$j = 3$
$i = 1$	$d_{11} = \frac{n_{1.} \times n_{.1}}{n}$ $= \frac{300}{550} \times 407$ $= 222$	$d_{12} = \frac{n_{1.} \times n_{.2}}{n}$ $= 72$	$d_{13} = \frac{n_{1.} \times n_{.3}}{n}$ $= 6$
$i = 2$	$d_{21} = 185$	$d_{22} = 60$	$d_{23} = 5$

Sur les données, on obtient :

$$d^2 = 29,499.$$

Par ailleurs, on lit :

$$q = 5,99.$$

Alors : $d^2 > q$: on est dans la zone de rejet : on rejette H_0 , et on conclut, au risque $\alpha = 5\%$, que X et Y ne sont pas indépendantes.

Calcul de la p-value.

Pour $Z \sim \chi^2_2$, on cherche :

$$\begin{aligned}
 \text{p-value} &= P(Z > d^2) \\
 &= 1 - P(Z < d^2) \\
 &< 0,001 \text{ (tables)}
 \end{aligned}$$

On peut calculer (logiciel) que $p\text{-value} = 3,9 \times 10^{-7}$.

On fait alors la même conclusion.

Exercice 2.

On cherche ici à vérifier si les données peuvent être des observations d'une w.a. suivant une loi de Poisson de paramètre λ .

Pour cela, on veut mettre en place un test d'adéquation à une loi.

Étape 1 : trouver la loi.

On connaît la famille de loi : Poisson.

Pour connaître la loi, il nous faut λ .

Or, pour $X \sim P(\lambda)$, on sait que $E(X) = \lambda$.

Avec nos observations, on a donc comme valeur

λ la plus probable $\lambda = \bar{x} = 1,5$.

Étape 2 : Test.

Hypothèses du test :

H_0 : "l'échantillon est la réalisation de wa $X_i \sim P(1,5)$, $i \in \{1 \dots 150\}$, iid"

H_1 : "l'échantillon n'est pas la réalisation de wa $X_i \sim P(1,5)$ iid, $i \in \{1 \dots 150\}$ ".

Statistique de test.

$$D^2 = \sum_{i=1}^l \frac{(n_i - d_i)^2}{d_i} \underset{H_0}{\sim} \chi^2_{l-1-r}$$

avec n_i : nombre d'observations de la modalité i , et d_i : nombre d'observations théoriques si on a une loi $P(1,5)$.

Le nombre de ddl du χ^2 est :

$$l - 1 - r$$

\nwarrow \searrow

nombre de modalités nombre de paramètres estimés

Zone de rejet.

Pour le risque $\alpha = 0.05$, on note q le quantile d'ordre $1-\alpha$ de la loi χ^2 à 5 ddl.
Alors : $A = \{ d^2 > q \}$.

Application.

$\forall i \in \{1 \dots 7\}$, on calcule :

$$d_i = 450 \times P(X = i | X \sim P(1,5))$$

On obtient :

	0	1	2	3	4	5	6
d	33	50	38	19	7	2	1

Pour pouvoir approximer la loi sous H_0 par une loi du χ^2 , il faut au moins 5 observations par classes alors on considère :

	0	1	2	3	≥ 4
n	32	54	34	21	9
d	33	50	38	19	10.

Si $f = 5$, $x_1 = 1$.

Donc $q = 7,81$. Par ailleurs on calcule $d^2 = 1,03$.

On ne se situe pas dans la zone de rejet.
Au risque $\alpha = 5\%$, on ne rejette pas H_0 , et on peut considérer que les piqûres de moustiques sont réparties selon une loi de Poisson de paramètre $\lambda = 1,5$.