

Correction TD10

E. Thulliez

2026-01-22

Exercice 1.

Mise en forme des données.

```
data <- read.table("pollutionData.txt", sep=';', header = TRUE)[, c(14, 16)]
colnames(data) = c("SO2", "Mortalité")

n = nrow(data) #n = 60 données
```

On note X la variable “indice de SO_2 ” et Y la variable “taux de mortalité”.

```
X <- data$SO2
Y <- data$Mortalité
```

Question 1.

On note x_i ($i \in \{1 \dots n\}$) : l’indice de SO_2 de la i -ème observation et y_i le taux de mortalité associé.

On suppose que les variables X et Y sont reliées par une relation linéaire :

$$Y_i = \underbrace{a + bX_i}_{\text{partie déterministe}} + \underbrace{E_i}_{\text{partie aléatoire}} \quad \forall i \in \{1 \dots n\}$$

avec $a \in \mathbb{R}$ et $b \in \mathbb{R}$ des paramètres à déterminer et avec les hypothèses suivantes : les $E_i \stackrel{iid}{\sim} \mathcal{N}(0, \sigma^2)$.

C’est-à-dire que les résidus (ou erreurs) sont

- centrés (le phénomène est expliqué par la partie déterministe)
- de variance constante (**homoscédasticité**)
- distribués selon une loi normale
- indépendants.

Question 2.

Les estimateurs $\hat{a}$ et $\hat{b}$ des paramètres a et b sont obtenus par la méthode des **moindres carrés ordinaires** (MCO / OLS), c’est-à-dire qu’ils vérifient :

$$(\hat{a}, \hat{b}) = \arg \min_{(a, b)} \sum_i (Y_i - a - bX_i)^2$$

Et leurs expressions sont données par :

$$\hat{a} = \bar{Y} - \hat{b}\bar{X} \quad \text{et} \quad \hat{b} = \frac{\text{Cov}(X, Y)}{S_X^2}$$

```
# Par la définition
b_hat = cov(Y,X)/var(X)
a_hat = mean(Y) - b_hat*mean(X)
```

On obtient alors

$$\begin{array}{c|c} \hat{a} & \hat{b} \\ \hline 917.89 & 0.42 \end{array}$$

Question 3.

Estimation de la variance.

On note $\hat{y}_i$ la prédiction de y_i à l'aide de notre modèle. Donc ici, $\hat{y}_i = \hat{a} + \hat{b}x_i$.

Or les erreurs observées vérifient $e_i = y_i - \hat{a} - \hat{b}x_i = y_i - \hat{y}_i$.

Le calcul de $\hat{y}_i$ nécessite l'estimation de deux paramètres, $\hat{a}$ et $\hat{b}$. Ainsi, pour produire un estimateur non biaisé de la variance, il nous faut $n - 2$ degrés de liberté, d'où l'expression suivante :

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_i (y_i - \underbrace{\hat{y}_i}_{=e_i})^2$$

```
y_hat = a_hat + b_hat*X
# Par la définition
s_hat = sum((Y - y_hat)**2)/(n-2)
```

Appliqué sur les données, on trouve que $\hat{\sigma}^2=3222.35$, et $\hat{\sigma}=56.77$.

Loi de l'estimateur.

L'estimateur $\hat{\sigma}^2$ vérifie la relation suivante :

$$\frac{(n-2)\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-2}^2$$

Construction de l'intervalle de probabilité

Remarque : Comment construire l'intervalle ? La relation précédente nous donne d'une part :

$$\mathbb{P}\left(\frac{(n-2) \times \hat{\sigma}^2}{\sigma^2} < \chi_{n-2, \alpha/2}^2\right) = \alpha/2 \quad (1)$$

$$\Rightarrow \mathbb{P}\left(\frac{(n-2) \times \hat{\sigma}^2}{\chi_{n-2, \alpha/2}^2} < \sigma^2\right) = \alpha/2 \quad (2)$$

$$\Rightarrow \mathbb{P}\left(\frac{(n-2) \times \hat{\sigma}^2}{\chi_{n-2, \alpha/2}^2} > \sigma^2\right) = 1 - \alpha/2 \quad (3)$$

$$(4)$$

Et de la même façon :

$$\mathbb{P}\left(\frac{(n-2) \times \hat{\sigma}^2}{\chi_{n-2,1-\alpha/2}^2} < \sigma^2\right) = 1 - \alpha/2 \quad (5)$$

$$\mathbb{P}\left(\frac{(n-2) \times \hat{\sigma}^2}{\chi_{n-2,1-\alpha/2}^2} > \sigma^2\right) = \alpha/2 \quad (6)$$

$$(7)$$

Si on regroupe :

$$\mathbb{P}\left(\frac{(n-2) \times \hat{\sigma}^2}{\chi_{n-2,\alpha/2}^2} > \sigma^2 > \frac{(n-2) \times \hat{\sigma}^2}{\chi_{n-2,1-\alpha/2}^2}\right) \quad (8)$$

$$= \mathbb{P}\left(\frac{(n-2) \times \hat{\sigma}^2}{\chi_{n-2,\alpha/2}^2} > \sigma^2\right) - \mathbb{P}\left(\frac{(n-2) \times \hat{\sigma}^2}{\chi_{n-2,1-\alpha/2}^2} > \sigma^2\right) \quad (9)$$

$$= 1 - \alpha \quad (10)$$

$$(11)$$

Intervalle de probabilités au niveau $1 - \alpha$.

La formule de l'intervalle de probabilité au niveau $1 - \alpha$ est donnée par :

$$\left[\frac{(n-2)\hat{\sigma}^2}{\chi_{n-2,1-\alpha/2}^2}; \frac{(n-2)\hat{\sigma}^2}{\chi_{n-2,\alpha/2}^2} \right]$$

Intervalle de confiance au niveau $1 - \alpha = 95\%$.

L'intervalle de confiance est la réalisation sur les données de l'intervalle de probabilités. On a ici :

```
alpha = 0.05
q1 <- qchisq(p = 1-alpha/2, df = n-2)
q2 <- qchisq(p = alpha/2, df = n-2)

IC_var = (n-2)*s_hat/c(q1,q2)
IC_sd = sqrt(IC_var)
```

On obtient :

- $IC_{95\%}(\sigma^2) = [2309.2; 4811.52]$
- $IC_{95\%}(\sigma) = [48.05; 69.37]$

Question 4.

Estimateur de a.

Loi de l'estimateur

$$\hat{a} \sim \mathcal{N}(a, \sigma_a^2) \quad \text{avec} \quad \sigma_a^2 = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{\sum (x_i - \bar{x})^2} \right)$$

Intervalle de probabilité

$$a \in [\hat{a} \pm \hat{\sigma}_a \times t_{n-2,1-\alpha/2}]$$

Intervalle de confiance à 95%

$$IC_{95\%}(a) = [898.3; 937.5]$$

Test $a = 0$ On pose les hypothèses de test suivantes :

$$\begin{cases} H_0 & a = 0 \\ H_1 & a \neq 0 \end{cases}$$

On considère ensuite la statistique de test T et on donne sa loi sous H_0 :

$$T = \frac{\hat{a}}{\hat{\sigma}_a} \underset{H_0}{\sim} T_{n-2}$$

La zone de rejet associée au test est donnée par :

$$R = \{|T| > t_{n-2, 1-\alpha/2}\}$$

Application numérique : pour $\alpha = 0.05$,

$$T_{obs} = 93.91 \text{ et } t_{n-2, 1-\alpha/2} = 2$$

Donc on se situe dans la zone de rejet, donc on rejette H_0 et on considère qu'au risque α a est significativement non-nul.

C'est cohérent avec le fait que $0 \notin IC_{95\%}(a)$.

Estimateur de b.

Loi de l'estimateur

$$\hat{b} \sim \mathcal{N}(b, \sigma_b^2) \quad \text{avec} \quad \sigma_b^2 = \frac{\sigma^2}{\sum_i (x_i - \bar{x})^2}$$

Intervalle de probabilité

$$b \in [\hat{b} \pm \hat{\sigma}_b \times t_{n-2, 1-\alpha/2}]$$

Intervalle de confiance à 95%

$$IC_{95\%}(b) = [0.18; 0.65]$$

Test $b = 0$ On pose les hypothèses de test suivantes :

$$\begin{cases} H_0 & b = 0 \\ H_1 & b \neq 0 \end{cases}$$

On considère ensuite la statistique de test T et on donne sa loi sous H_0 :

$$T = \frac{\hat{b}}{\hat{\sigma}_b} \underset{H_0}{\sim} T_{n-2}$$

La zone de rejet associée au test est donnée par :

$$R = \{|T| > t_{n-2, 1-\alpha/2}\}$$

Application numérique : pour $\alpha = 0.05$,

$$T_{obs} = 3.55 \text{ et } t_{n-2, 1-\alpha/2} = 2$$

Donc on se situe dans la zone de rejet, donc on rejette H_0 et on considère qu'au risque α b est significativement non-nul.

C'est cohérent avec le fait que $0 \notin \text{IC}_{95\%}(b)$.

Question 5.

Somme des carrés totale :

$$SCT = \sum_i (y_i - \bar{y})^2 = (n-1)S_Y^2 = 224438$$

Somme des carrés résiduels :

$$SCR = \sum_i (y_i - \hat{y}_i)^2 = 186896.2$$

Somme des carrés expliqués par le modèle :

$$SCM = SCT - SCR = 37541.8$$

Coefficient de détermination : R^2

$$R^2 = \frac{SCM}{SCT} = 1 - \frac{SCR}{SCT} = 0.17$$

Idéalement, le R^2 doit être proche de 1. Ici $R^2 = 0.17$ signifie que la modèle explique 17% de la variance des observations de Y .

Question 6.

Pour $x = 100$.

On donne $x_0 = 100$. On a alors $\hat{y}_0 = \hat{a} + \hat{b}x_0 = 959.7$

L'intervalle de probabilité/confiance en espérance : il consiste à voir $\hat{y}_0$ comme une estimation de l'espérance de Y_0 .

Il se base sur la relation suivante :

$$\frac{\hat{y}_0 - \mathbb{E}(Y_0)}{\hat{\sigma} \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_i (x_i - \bar{x})^2}}} \sim T_{n-2}$$

Et est alors définit par :

$$\text{IP}_{1-\alpha}(\mathbb{E}(Y_0)) = \left[\hat{y}_0 \pm t_{n-2, 1-\alpha/2} \sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_i (x_i - \bar{x})^2} \right)} \right]$$

[941.2, 978.2]

L'intervalle de probabilité/confiance en prédiction : il consiste à voir $\hat{y}_0$ comme une estimation de Y_0 .

Il se base sur la relation suivante :

$$\frac{\hat{y}_0 - Y_0}{\hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_i (x_i - \bar{x})^2}}} \sim T_{n-2}$$

Et est alors défini par :

$$\text{IP}_{1-\alpha}(Y_0) = \left[\hat{y}_0 \pm t_{n-2, 1-\alpha/2} \sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_i (x_i - \bar{x})^2} \right)} \right]$$

[844.6, 1074.8]

Pour $x = 250$.

On donne $x_0 = 250$. On a alors $\hat{y}_0 = 1022.4$

L'intervalle de probabilité/confiance en espérance :

[973.9, 1070.9]

L'intervalle de probabilité/confiance en prédiction :

[898.8, 1146]

L'intervalle de confiance est plus étroit pour $x = 100$ que $x = 250$ car cette valeur est plus proche de la moyenne des observations $\bar{x}$.

Question 7.

D'après le premier graphe (énoncé), la linéarité entre X et Y n'est pas évidente. Cela est confirmé par un R^2 de 17%, ce qui est plutôt faible. On peut imaginer que l'indice de SO_2 a un impact sur le taux de mortalité (ce qui est justifié par le test $b \neq 0$), mais qu'il ne l'explique pas complètement.

Question 8.

Le graphe des résidus ne présente pas de dynamique particulière en fonction de l'indice de SO_2 (les e_i ne dépendent pas des x_i). Ils sont bien centrés autour de la droite $y = 0$, et il semble que l'hypothèse d'homoscédasticité soit vérifiée (pour toutes les valeurs de x , les e_i oscillent entre -100 et 100). Enfin, on voit qu'il y a une valeur aberrante, avec un résidu à 200 pour un x_i nul.

Le second graphe représente :

- le nuage de point initial.
- les prédictions par la droite.
- l'intervalle de confiance sur la prédiction en fonction de la valeur de x .
- les bandes de confiance à $1.96\hat{\sigma}$.

Comme évoqué précédemment, on remarque une valeur aberrante pour un très faible x_i , ce qui correspond probablement à la valeur aberrante retrouvée dans les résidus.

Également, les valeurs observées sont rarement dans l'intervalle de confiance sur la prédiction. Cela s'explique par le fait que pour de faibles valeurs de x , on observe de grandes variations de y . Or ce sont les valeurs de x les plus présentes dans le jeu de données, et donc, celles pour lesquelles l'intervalle de confiance est le plus resserré. Comme pour la question précédente, on peut ici supposer que la simple utilisation du SO_2 pour expliquer le taux de mortalité n'est pas suffisant.